


Evidencia de Aprendizaje N°2

MODELADO PREDICTIVO Y CLASIFICACIÓN DE AUDIO



Materia: Técnicas de Procesamiento del Habla.

Cohorte: 2024.

Integrantes:

- Barbero, Maciel
- Molina, Jonathan
- Molina, Mauricio

Docente: Rubén Emmanuel Giúdice Bojanich

[Link a Google colab](#)

Bitácora de Experimentación y Métricas

A continuación se consolidan las respuestas correspondientes al diseño experimental ejecutado sobre el dataset ESC-50 filtrado (clases: dog, rain, sea, wind) enfocado en la robustez de los modelos y la selección de características estadísticas de audio.

1 ¿Qué ocurre si eliminas StandardScaler antes de SVM?

En caso de eliminar StandardScaler antes de SVM, el accuracy de este modelo bajaría ya que se produciría un sesgo. Se debe tener presente que el SVM es un algoritmo geométrico que para poder hacer una separación de clases, calcula la distancia euclidiana entre los puntos en un mapa espacial; por lo que al no estandarizar, el modelo se sesgará dándole mayormente importancia a las variables con magnitudes grandes (como por ejemplo centroide y rolloff, que se expresa en miles de Hz) y despreciando a las variables con magnitudes pequeñas (ZCR, RMS, etc, que se expresan en decimales). Hacer la estandarización es necesario para evitar este sesgo, ya que transforma las magnitudes de las variables y las lleva a una escala en común (media 0 y varianza 1). Por otra parte, de no estandarizar, el tiempo de convergencia aumentaría porque el espacio de optimización es matemáticamente inestable y distorsionado, obligando al algoritmo a realizar un número mucho mayor de iteraciones para encontrar el hiperplano de separación óptimo.

- Captura de métricas

Tabla comparativa: CON vs SIN STANDARDSCALER

MÉTODO / CONFIGURACIÓN	CV ACCURACY (MEAN)	TIEMPO DE CÓMPUTO
SVM (Con Escalado)	0.9589 ± 0.038	0.043666 s
SVM (Sin Escalado)	0.8653 ± 0.069	0.045798 s

Comparación de Accuracy y tiempos de convergencia

Al evaluar el impacto de no aplicar el escalamiento (StandardScaler) antes de SVM, los datos de la experimentación reflejan lo siguiente:

- Degradación del Accuracy: se experimentó una caída directa del 9.36% en el rendimiento general, haciendo que el CV Accuracy (Mean) pase de un sólido 0.9589 a un 0.8653.
- Pérdida de Estabilidad: sin el escalado, el modelo se vuelve considerablemente menos consistente entre las distintas particiones, reflejado en el aumento de la desviación estándar que sube de ± 0.038 a ± 0.069 .
- Tiempo de Cómputo: si bien aumentó el tiempo de ejecución, esta variación no fue de considerable magnitud (pasó de 0.043666 a 0.045798 segundos), lo que demuestra que el costo computacional de aplicar la estandarización es despreciable frente al enorme beneficio que aporta en precisión.

2 Agrega ruido blanco al 20% del conjunto de test y re-evalúa.

- Captura de métricas

```


División: 96 train | 24 test



Ruido blanco inyectado con éxito en 4 muestras aleatorias del conjunto de test.



Entrenando Random Forest...



CV Accuracy (5-fold): 0.928 ± 0.061



Entrenando SVM (RBF)...



CV Accuracy (5-fold): 0.959 ± 0.038



Modelo seleccionado para evaluación: SVM



RE-EVALUACIÓN DE ROBUSTEZ ANTE RUIDO (TEST ACCURACY):



-----



Test Accuracy RANDOM FOREST (Con 20% de ruido): 0.875



Test Accuracy SVM (Con 20% de ruido): 0.917



-----


```

¿Qué modelo es más resiliente: RF o SVM? ¿Por qué?

Tras agregar ruido blanco en un 20% al conjunto de Test de cada modelo, se observó que Random Forest sufrió una disminución mayor en el Test de Accuracy, cayendo a 0.875 (-0.053 o 5.3%, respecto del original), mientras que SVM bajó a 0.928 (-0.042 o 4.2%, respecto del original). Por lo que en este caso, el modelo que menor variación sufrió fue el SVM, convirtiéndolo en el más resiliente.

Esto se fundamenta en que la SVM consolidó un hiperplano con un margen geométrico amplio y robusto, impidiendo que el leve desplazamiento espacial de las muestras alteradas afectara la clasificación. En cambio, Random Forest se vio más afectado debido a que las perturbaciones alteraron los valores por fuera de los umbrales lógicos estrictos de sus árboles, un impacto crítico al evaluar un conjunto de test acotado de 24 muestras.

3 Reduce el vector de 86 a 20 features usando SelectKBest.

- Captura de métricas

```
=====
REDUCCIÓN DE DIMENSIONALIDAD: De 86 features a 20
=====
```

```
EVALUACIÓN DEL MODELO REDUCIDO:
```

- SVM con 20 Features - CV Accuracy (5-fold): 0.928 ± 0.051

```
LAS 20 FEATURES SOBREVIVIENTES:
```

```
-----
1 | MFCC Coef 0 [Promedio Mean]
2 | MFCC Coef 1 [Promedio Mean]
3 | Spectral Centroid (Brillo) [Promedio Mean]
4 | Spectral Rolloff (Frec. Corte) [Promedio Mean]
5 | MFCC Coef 0 [Varianza Std]
6 | MFCC Coef 1 [Varianza Std]
7 | MFCC Coef 2 [Varianza Std]
8 | MFCC Coef 3 [Varianza Std]
9 | MFCC Coef 4 [Varianza Std]
10 | MFCC Coef 5 [Varianza Std]
11 | MFCC Coef 8 [Varianza Std]
12 | Delta MFCC 0 [Varianza Std]
13 | Delta MFCC 1 [Varianza Std]
14 | Delta MFCC 2 [Varianza Std]
15 | Delta MFCC 3 [Varianza Std]
16 | Delta MFCC 4 [Varianza Std]
17 | Delta-Delta MFCC 0 [Varianza Std]
18 | Delta-Delta MFCC 1 [Varianza Std]
19 | Delta-Delta MFCC 2 [Varianza Std]
20 | Delta-Delta MFCC 3 [Varianza Std]
-----
```

¿Se mantiene el accuracy?

El accuracy no se mantuvo, ya que sufrió una leve degradación. El CV Accuracy de la SVM descendió del 0.959 ± 0.038 (con las 86 características originales) a un 0.928 ± 0.051 al reducir el vector a 20. Esto demuestra que las 66 características eliminadas no eran puramente redundantes, sino que aportaban información secundaria útil que le permitía a la SVM estabilizar y ajustar con mayor precisión su hiperplano de decisión.

¿Qué features sobrevivieron?

Al analizar las 20 características seleccionadas por SelectKBest, se observa la siguiente distribución y composición:

- **Predominancia de la variabilidad ([Varianza Std]):** el filtro conservó 16 medidas de desviación estándar frente a solo 4 medidas de promedio. Las variables basadas en la variación temporal dominaron casi por completo la selección.
- **Componentes Mel (MFCCs y sus derivadas):** representan el grueso de las sobrevivientes con 18 de los 20 lugares:

MFCCs base: Quedaron 2 en promedio (Coef 0 y Coef 1) y 6 en varianza (Coef 0, 1, 2, 3, 4, 5 y 8).

Deltas: Quedaron 5 en varianza (Coef 0, 1, 2, 3 y 4).

Delta-Deltas: Quedaron 4 en varianza (Coef 0, 1, 2 y 3).

- **Características espectrales de brillo:** solo sobrevivieron 2 variables de esta familia, y ambas quedaron seleccionadas únicamente en su métrica de promedio: Spectral Centroid y Spectral Rolloff. Las familias restantes del script original (como ZCR y RMS) fueron descartadas por completo en ambas métricas.

Enlaces a GitHub

[Link al repositorio grupal](#)

[Link al repositorio de Maciel Barbero](#)

[Link al repositorio de Jonathan Molina](#)

[Link al repositorio de Mauricio Molina](#)