

Evidencia de Aprendizaje N°3

Integración de LLMs y Arquitecturas Generativas en el Procesamiento del Habla



Materia: Técnicas de Procesamiento del Habla.

Cohorte: 2024.

Integrantes:

- Barbero, Maciel
- Molina, Jonathan
- Molina, Mauricio

Docente: Rubén Emmanuel Giúdice Bojanich

Informe Técnico

Consigna 1: Evolución y Ruptura Paradigmática

¿Qué componentes se eliminan, qué se reemplazan y qué se conservan?

Para el desarrollo de esta consigna se comparará un pipeline clásico de ASR (MFCC + HMM + GMM) con SpeechLM.

Componentes que se eliminan

En el paradigma tradicional del reconocimiento automático del habla, el procesamiento de la voz dependía de un pipeline fragmentado y secuencial de bloques independientes. El primer componente eliminado es el extractor manual de características físicas, que se encargaban de calcular los coeficientes cepstrales en las frecuencias Mel o las predicciones lineales conceptuales. Estos algoritmos aplican transformaciones matemáticas fijas como la transformada rápida de Fourier, bajo el supuesto de que solo ciertas bandas de frecuencia inspiradas en la cóclea eran relevantes (Rabiner, 1989).

El segundo componente eliminado fueron los modelos de mezclas Gaussianas, estos se encargan de llevar a cabo el modelado acústico estático calculando las probabilidades de que un vector de características perteneciera a un estado fonético específico.

Por último, se descartaron los modelos ocultos de Markov, que son utilizados para el alineamiento temporal. Los HMM gestionan la naturaleza secuencial del habla bajo la asunción de que las transiciones fonéticas se rigen por estados probabilísticos discretos de corto alcance (Gales & Young, 2008).

Al integrarse todo en SpeechLM, se elimina el acoplamiento difuso de estos bloques independientes y de esta manera se erradica el fenómeno de "error en cascada", en donde una distorsión acústica originada en los MFCC corrompía irreversiblemente las decisiones estadísticas del GMM y el HMM (Graves al., 2006).

Componentes que se reemplazan

Arquitecturas unificadas diferenciables de extremo a extremo sustituyeron la fragmentación del pipeline clásico.

El bloque de extracción acústica tradicional (MFCC + GMM) fue reemplazado por un frente de onda convolucional profundo y un cuantizador vectorial residual (RVQ), implementado típicamente en codificadores neuronales como EnCodec (Défossez et al., 2022). Este componente comprime la señal de audio continua directamente en representaciones latentes discretas, aprendiendo las fronteras acústicas de forma adaptativa.

Por su parte, el modelado de la dinámica temporal que antes era controlado por las cadenas de Markov del HMM se reemplazó por el mecanismo de autoatención (Self-Attention) de la arquitectura Transformer (Vaswani et al., 2017). Mientras que el HMM estaba limitado por la propiedad de Márkov, donde el estado actual solo depende del inmediato anterior, la autoatención permite capturar dependencias temporales de largo alcance no locales, computando la relación de cada segmento de audio con la totalidad de la secuencia simultáneamente.

Finalmente, la interfaz de salida que antes requería un diccionario fonético rígido y un decodificador de grafemas se reemplazó por un espacio latente unificado mediante alineación cross-modal (Hsu et al., 2021). A través de capas de proyección lineal o adaptadores neuronales, los embeddings acústicos se mapean directamente al mismo espacio vectorial que los tokens de texto del LLM, transformando el reconocimiento de voz en una tarea de traducción de secuencias puras.

Componentes que se conservan

A pesar del cambio drástico en las herramientas matemáticas, la física de la señal de voz humana impone restricciones que obligan a conservar ciertos principios fundamentales. Se conservó la necesidad de explotar la invarianza temporal y espectral de la señal acústica (O'Shaughnessy, 2000). Aunque SpeechLM no use filtros manuales, las redes neuronales convolucionales unidimensionales que operan en su capa de entrada actúan matemáticamente de forma homóloga a los bancos de filtros clásicos, procesando el audio en ventanas temporales superpuestas para capturar la variación de la presión del aire. Asimismo, se conservó la exigencia de modelar la variabilidad acústica intrínseca del hablante (timbre, velocidad, intensidad y variaciones fonéticas locales), delegando ahora en las capas profundas del Transformer la capacidad de normalizar estas diferencias sin necesidad de algoritmos de normalización de varianza externos (Radford et al., 2023). Por último, se conservó y potenció el componente de modelado de lenguaje. En los sistemas tradicionales, el modelo de lenguaje operaba de forma externa mediante restricciones estadísticas restrictivas (N-gramas) para desempatar fonemas ambiguos. En SpeechLM, el modelado del lenguaje se conserva como el núcleo axiomático del sistema: se asume que la decodificación del habla es un problema de predicción lingüística condicional donde el contexto semántico masivo del LLM guía, rectifica y otorga significado a la señal acústica difusa (Speech-to-Text y Text-to-Speech combinados).

¿Cómo cambia la noción de "característica" al pasar de handcrafted features a embeddings autosupervisados?

La noción de "característica" ha sufrido un cambio significativo al pasar del paradigma clásico del reconocimiento del habla hacia las arquitecturas basadas en SpeechLM. En el paradigma clásico del reconocimiento del habla la noción de "característica" hace referencia a una representación estática ya que es una medición física, rígida y matemática de la onda de sonido en un instante aislado (generalmente de 25ms), que no tiene en cuenta su contexto y que fue diseñada por un humano. En contraposición, con los embeddings autosupervisados la noción de "característica" termina siendo una representación matemática profunda y flexible que el modelo optimiza de manera autónoma, no se basa en el sonido aislado, sino que lo entiende dentro de una secuencia combinando acústica y semántica en un solo vector.

En conclusión, se pasó de medir la física del sonido con una regla física a ubicarlo en un mapa mental que entiende también el contexto, lo cual le da robustez ante la imperfección del mundo real, siendo este el beneficio principal. Al unificar la señal acústica y el significado lingüístico en un mismo espacio vectorial, el modelo ya no depende enteramente de la pureza física del audio de entrada y, de esta manera, ante factores críticos como el ruido ambiente, la distorsión provocada por los micrófonos o las inflexiones imprevistas de la voz, la arquitectura del SpeechLM es capaz de deducir y rectificar la información, apoyándose en

la coherencia semántica de la secuencia, garantizando tasas de error significativamente menores y un rendimiento mucho más estable.

¿Por qué la tokenización de audio es un puente necesario hacia los LLMs?

La tokenización de audio es un "puente" necesario hacia los LLMs ya que resuelve el problema de fondo, que es la incompatibilidad de naturalezas de datos que existe entre la señal acústica y los modelos de lenguaje. Un LLM por definición es un procesador simbólico y discreto, por lo cual solamente trabaja con elementos contables, separados y con límites claros (tokens) para poder calcular probabilidades matemáticas. Por otro lado, una onda de sonido es una señal analógica que es continua e infinita que cuando se digitaliza, se obtiene como resultado una gran cantidad de números decimales que se miden miles de veces por segundo y si un LLM intentara trabajar con esta cantidad de números continuos colapsaría. El mecanismo de atención de los Transformers calcula la relación de cada elemento con todos los demás y una secuencia de audio de apenas unos segundos de duración, generaría millones de combinaciones matemáticas causando que el procesamiento no sea viable a nivel computacional (Vaswani et al., 2017). Es por ello que la tokenización de audio es la solución, ya que actúa como puente para que señales acústicas analógicas puedan ser procesadas por LLMs. Este proceso se logra mediante codificadores neuronales que comprimen y cuantizan el flujo continuo de la onda, transformándolo en una secuencia ordenada de símbolos numéricos discretos o tokens acústicos (Défossez et al., 2022; Zeghidour et al., 2021). Al equiparar el sonido con el formato estructural de las palabras escritas, se habilita una verdadera convergencia multimodal; el mecanismo de atención del Transformer puede integrar y procesar texto y audio bajo un mismo espacio latente y con un costo computacional eficiente (Borsos et al., 2023), permitiendo que el modelo no solo transcriba el habla de forma mecánica, sino que co-diseñe el sentido semántico y prosódico de la secuencia completa.

Consigna 2: Ajuste de Modelos y Dominio

Para el desarrollo de esta consigna, se eligió la atención al cliente en zonas rurales como dominio de aplicación.

La implementación de un SpeechLM para la atención al cliente en contextos rurales requiere implementar una estrategia de adaptación que sea capaz de optimizar los recursos computacionales, garantice la robustez del modelo ante señales acústicas posiblemente degradadas y dependiendo de la región, posibles variaciones lingüísticas dialectales.

Justifica la elección entre fine-tuning completo, LoRA o prompt-tuning

Para el dominio seleccionado, la estrategia teórica adoptada es LoRA (*Low-Rank Adaptation*). Se la considera la más adecuada descartando el *Fine-Tuning* completo y el *Prompt-Tuning*.

Por un lado, no se seleccionó el *Fine-Tuning* completo debido a que la modificación de la totalidad de los miles de millones de parámetros de un SpeechLM exige una infraestructura de cómputo masiva y un volumen de datos gigantesco, sumado a que induce al riesgo de olvido catastrófico (*catastrophic forgetting*), lo cual destruiría las capacidades generales de

comprensión lingüística y prosódica que el modelo base adquirió durante su preentrenamiento masivo (Radford et al., 2023).

Por otro lado, se descartó el *Prompt-Tuning* porque, aunque es una alternativa computacionalmente ligera que añade tokens virtuales aprendibles al inicio de la secuencia, no tiene la capacidad plástica necesaria para reconfigurar el modelado acústico de bajo nivel; por lo tanto, al no modificar los pesos internos del Transformer, resulta incapaz de alterar la manera en que el modelo procesa ruidos ambientales severos o las variantes fonéticas regionales que se encuentran fuera de la distribución del dataset de preentrenamiento.

Es por ello que se seleccionó LoRA, ya que congela los pesos preentrenados del modelo base e introduce matrices de descomposición de bajo rango adaptables en las capas de atención (especialmente en las proyecciones de *Query* y *Value*) (Hu et al., 2021).

Para el dominio seleccionado presenta tres ventajas clave:

1. Preservación del conocimiento base: el modelo retiene su robustez lingüística global mientras las submatrices de LoRA se especializan exclusivamente en aprender a mapear los acentos locales y a filtrar los ruidos específicos del entorno rural.
2. Eficiencia en datos: reduce drásticamente el número de parámetros entrenables (menos del 1%), lo que disminuye el riesgo de sobreajuste cuando los datasets de dominios específicos son acotados.
3. Despliegue modular: permite intercambiar "adaptadores" LoRA livianos sobre un mismo modelo base en producción, facilitando la especialización por regiones geográficas o dialectos sin duplicar los costos de almacenamiento en servidores.

Describe cómo manejarías datos escasos, desbalanceados o con ruido

Para el desarrollo de un SpeechLM orientado a la atención de usuarios en regiones rurales enfrentaríamos tres desafíos metodológicos críticos en su arquitectura de datos: la escasez de muestras etiquetadas, el sesgo estadístico por desbalance de variantes y la degradación de la señal acústica.

Para mitigar el impacto del ruido ambiental no estacionario (como el viento o la maquinaria) y las interferencias de canales analógicos, se propone una estrategia de aumento de datos acústicos (*Data Augmentation*) mediante la inyección sintética de perturbaciones robustas; utilizando algoritmos de enmascaramiento de frecuencia y tiempo, el modelo es forzado a extraer patrones fonéticos invariantes, abstrayéndose de las condiciones del entorno físico (Park et al., 2019).

Ante la escasez de transcripciones manuales locales, se optaría por un enfoque de aprendizaje semi-supervisado (*self-training*), donde el modelo base preentrenado procesa grandes volúmenes de audio rural no etiquetado y genera pseudo-etiquetas de alta confianza que luego realimentan el ajuste fino de las matrices de bajo rango (Kahn et al., 2020).

Finalmente, para neutralizar el desbalance dialectal y evitar que el sistema penalice las variantes lingüísticas de comunidades geográficamente minoritarias, se aplicará un esquema de ponderación en la función de pérdida (*Weighted Cross-Entropy Loss*); esta técnica asigna un peso inversamente proporcional a la frecuencia de aparición de cada variante en el dataset de entrenamiento, garantizando una representación matemática equitativa y un desempeño inclusivo de la red independientemente de la procedencia del hablante.

Explica cómo evaluarías la adaptación sin sobreajuste (métricas, validación, métricas de dominio)

Para validar la adaptación del SpeechLM y mitigar el riesgo de sobreajuste al dominio, la estrategia de evaluación se estructurará bajo un diseño metodológico de tres ejes.

En primer lugar, el proceso de validación prescindirá de la división aleatoria tradicional y adoptará un enfoque de validación cruzada por exclusión de hablantes (*Speaker-Omitted Cross-Validation*); de este modo, el conjunto de testeo estará integrado exclusivamente por grabaciones de usuarios cuyos perfiles acústicos y dialectales jamás fueron expuestos en la fase de entrenamiento, garantizando que las métricas reflejen una capacidad real de generalización y no la memorización de timbres de voz específicos.

En segundo lugar, la evaluación del rendimiento combinará métricas acústicas y semánticas: se utilizará la tasa de error de palabras (*Word Error Rate*, WER) para medir la precisión estricta de la transcripción, coordinada con la métrica *BERTScore* (Zhang et al., 2019), la cual recurre al análisis de *embeddings* contextuales para evaluar la equivalencia semántica de la respuesta generada; esto permite validar la comprensión de la intención del usuario respetando el uso de localismos o sinónimos dialectales sin penalizarlos de forma rígida. Por último, se incorporarán métricas específicas del dominio de aplicación vinculadas al impacto del sistema, tales como la tasa de resolución en la primera llamada (FCR) y un control periódico de degradación (*catastrophic forgetting*) mediante la evaluación del modelo ajustado sobre *datasets* estándar de referencia (como *Librispeech*); un incremento anómalo en el WER de este corpus de control indicará un sobreajuste al entorno rural, operando como una alerta temprana para calibrar los hiperparámetros de regularización de las matrices de bajo rango.

Consigna 3: Despliegue, Ética y Sociedad

El despliegue de un sistema multimodal de voz basado en SpeechLM en un entorno real de producción trasciende la optimización algorítmica, exigiendo un análisis crítico de sus implicancias éticas, operativas y de gobernanza sociotécnica.

Latencia vs. calidad: ¿qué compromisos teóricos son inevitables?

En el despliegue de sistemas conversacionales de voz basados en SpeechLM, el compromiso entre latencia y calidad constituye un límite teórico e infraestructural insalvable. Para que una interacción fluida en tiempo real sea percibida como natural por el ser humano, la latencia de extremo a extremo (*end-to-end*) no debe superar el umbral crítico de los 200 a 300 milisegundos. Sin embargo, la arquitectura de un SpeechLM introduce un retraso acumulativo derivado de tres procesos secuenciales inevitables: la tokenización acústica y codificación del audio de entrada, la inferencia autorregresiva del Transformer que genera los tokens de respuesta uno a uno mediante costosos cálculos de autoatención y, finalmente, la de-tokenización o síntesis de la onda de audio de salida (TTS). Para aproximarse a los tiempos exigidos en producción, la ingeniería de sistemas se ve obligada a sacrificar la calidad y la profundidad del modelo mediante compromisos teóricos drásticos. Esto implica reducir la complejidad del Transformer a través de técnicas de cuantización de pesos (por ejemplo, transicionar de precisión flotante de 32 bits a formatos enteros de 8 o 4 bits) o aplicar destilación de conocimiento para operar con modelos con menor cantidad de parámetros. Si bien estas optimizaciones alivian la carga computacional y aceleran la

velocidad de inferencia, limitan severamente la capacidad del modelo para captar matices prosódicos finos, interpretar contextos lingüísticos altamente complejos o mantener la coherencia conceptual en diálogos prolongados.

Privacidad biométrica: ¿cómo garantizarías que la voz no se almacene ni se use indebidamente?

La voz humana constituye un dato biométrico único e inalterable que expone no solo la identidad inequívoca del hablante, sino también rasgos sensibles como su estado emocional o condiciones de salud. En un entorno de producción, garantizar que esta huella acústica no sea almacenada ni explotada indebidamente exige un marco de seguridad basado en el principio de privacidad por diseño (*Privacy by Design*). Para lograrlo, la arquitectura del sistema debe implementar un procesamiento estrictamente efímero y volátil: el flujo de audio continuo recibido de las regiones rurales debe ser decodificado directamente en la memoria RAM del servidor de inferencia y destruido de forma inmediata tras su conversión a tokens discretos, prohibiendo explícitamente cualquier persistencia o escritura en discos duros o bases de datos de registros (*logs*). En caso de que se requieran muestras para auditorías de calidad o reentrenamiento, se debe integrar un pipeline de anonimización acústica inversa antes de cualquier almacenamiento; este proceso altera los formantes y el tono fundamental de la señal para remover los componentes de identidad biológica del usuario, preservando únicamente la información fonética y semántica abstracta necesaria para el análisis técnico, blindando así al sistema contra filtraciones de identidad o vigilancias biométricas no autorizadas.

Sesgo y accesibilidad: ¿cómo evitarías que el sistema excluya acentos, dialectos o patologías del habla?

Los modelos lingüísticos y acústicos basados en aprendizaje profundo padecen un sesgo estructural denominado "centralismo de datos", desempeñándose con tasas de error significativamente mayores ante variantes lingüísticas minoritarias, sociolectos regionales o usuarios con patologías del habla. Para evitar que el sistema actúe como una barrera de exclusión tecnológica, se debe implementar una estrategia de accesibilidad universal basada en la resiliencia algorítmica. Más allá de la ponderación matemática implementada durante el ajuste fino mediante funciones de pérdida balanceadas, el sistema en producción debe integrar un mecanismo dinámico de conmutación adaptativa de confianza. Cuando el codificador acústico detecta una señal con una entropía inusualmente alta (indicador de una interrupción prosódica por patología o de un acento no indexado en los datos base), el sistema debe relajar sus umbrales de coincidencia fonética estricta y reconfigurar el mecanismo de atención del Transformer para que priorice el modelado de contexto semántico (*embeddings* contextuales); esto permite deducir la intención global de la consulta del usuario en lugar de rechazar el audio por desajustes en la pronunciación, eludiendo bucles de frustración y garantizando un acceso equitativo al servicio.

Propón un marco teórico de gobernanza (auditorías, transparencia, consentimiento) alineado con estándares internacionales.

El despliegue ético y operativo del SpeechLM requiere un marco teórico de gobernanza tecnológica robusto, estructurado sobre los principios de responsabilidad (*accountability*) y alineado con los estándares internacionales más exigentes, como la Ley de Inteligencia

Artificial de la Unión Europea (*EU AI Act*) y las directrices éticas de la OCDE. Este modelo de gobernanza se articula bajo un enfoque tridimensional:

- Consentimiento Explícito, Informado y Gradual: de acuerdo con las directrices de privacidad global, el sistema iniciará toda interacción notificando de manera transparente e inequívoca al usuario que está interactuando con una interfaz conversacional automatizada. Se solicitará una validación biométrica de consentimiento mediante comandos de voz claros y accesibles para la población target, especificando de forma desagregada el propósito del procesamiento de la señal y garantizando el derecho a la revocación inmediata y al borrado de los tokens generados.
- Auditorías de Sesgo Algorítmico y Transparencia (*Algorithmic Auditing*): se establecerá un protocolo de auditorías ciegas y periódicas a cargo de un comité multidisciplinario independiente. Estas evaluaciones medirán la equidad del rendimiento del modelo (*Fairness Metrics*), verificando estadísticamente que las tasas de error estructural (WER y BERTScore) no presenten desviaciones o variaciones significativas entre diferentes grupos demográficos, etarios, regionales o con variaciones en el habla, asegurando la trazabilidad de los datos utilizados en los adaptadores LoRA.
- Mecanismo de Supervisión Humana en el Bucle (*Human-in-the-Loop*): el marco de gobernanza define límites estrictos a la autonomía de la IA. Ante la detección de umbrales altos de incertidumbre semántica, expresiones de vulnerabilidad por parte del usuario o fallos reiterados en la comprensión debido a factores acústicos extremos, el sistema ejecutará una transferencia prioritaria, transparente y sin fricciones hacia un operador humano, garantizando que el SpeechLM opere exclusivamente como un entorno de asistencia complementario y nunca como un decisor autónomo absoluto en la gestión del servicio.

Conclusión

La transición desde los sistemas tradicionales de procesamiento del habla hacia los modelos de lenguaje de voz de extremo a extremo (*SpeechLMs*), pone de manifiesto que la verdadera disrupción de este cambio de paradigma no es únicamente matemática, sino conceptual. Al desplazarse las mediciones físicas y aisladas de las características diseñadas a mano e integrar el audio en espacios de representación semántica unificados, la Inteligencia Artificial ha comenzado a procesar el habla no como un fenómeno puramente acústico, sino como un acto lingüístico indisoluble de su contexto. Sin embargo, el examen crítico de su despliegue en entornos reales de alta vulnerabilidad (como por ejemplo la atención al cliente en regiones rurales, dominio elegido en esta evidencia de aprendizaje) obliga a desmitificar la supuesta neutralidad de los algoritmos. La implementación de soluciones como la adaptación de bajo rango (LoRA), el enmascaramiento acústico para entornos ruidosos y las funciones de pérdida balanceadas demuestra que los desafíos técnicos ya no se resuelven persiguiendo una pureza de datos que es difícil de alcanzar, sino diseñando sistemas resilientes a la variabilidad del mundo real. Desde una perspectiva ética y de gobernanza, el verdadero éxito de estas tecnologías no se medirá por la reducción marginal de la tasa de error de palabras, sino por su capacidad de inclusión. Mitigar los sesgos derivados del centralismo de datos, proteger la privacidad frente a la explotación de rasgos biométricos e implementar marcos institucionales transparentes con supervisión



humana son requisitos obligatorios para evitar que la innovación amplíe las brechas de exclusión social existentes. Al final, el verdadero avance en este campo no se mide por la potencia de las computadoras, sino por el impacto real en las personas. El "puente" que construyen estos modelos de lenguaje debe servir para acercar y conectar distintas realidades sociales en lugar de aislarlas.

Referencias

- Borsos, Z., Marinier, R., Vincent, D., Kharitonov, E., Pietquin, O., Sharifi, M., Teeuwen, R., Tagliasacchi, M., & Zeghidour, N. (2023). AudioPaLM: A large language model that can speak and listen. arXiv preprint arXiv:2306.12925. <https://doi.org/10.48550/arXiv.2306.12925>
- Défossez, A., Copet, J., Synnaeve, G., & Adi, Y. (2022). High fidelity neural audio compression. arXiv preprint arXiv:2210.13438. <https://doi.org/10.48550/arXiv.2210.13438>
- European Parliament. (2024). Artificial Intelligence Act: European Parliament legislative resolution of 13 March 2024 on the proposal for a regulation of the European Parliament and of the Council laying down harmonised rules on Artificial Intelligence. Briefing: EU Legislation in Progress.
- Gales, M., & Young, S. (2008). The application of hidden Markov models in speech recognition. Foundations and Trends® in Signal Processing, 1(3), 195–304. <https://doi.org/10.1561/20000000004>
- Graves, A., Fernández, S., Gomez, F., & Schmidhuber, J. (2006). Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks. In Proceedings of the

23rd International Conference on Machine Learning (pp. 369–376).

ACM. <https://doi.org/10.1145/1143844.1143891>

Hsu, W. N., Bolte, B., Tsai, Y. H. H., Lakhota, K., Salakhutdinov, R.,
& Mohamed, A. (2021). HuBERT: Self-supervised speech
representation learning by masked prediction of hidden units.
IEEE/ACM Transactions on Audio, Speech, and Language Processing,
29, 3451–3460.
<https://doi.org/10.1109/TASLP.2021.3122291>

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S.,
Wang, L., & Chen, W. (2021). LoRA: Low-rank adaptation of large
language models. arXiv preprint arXiv:2106.09685.
<https://doi.org/10.48550/arXiv.2106.09685>

Kahn, J., Lee, A., & Hannun, A. (2020). Self-training for end-to-end
speech recognition. In ICASSP 2020 - 2020 IEEE International
Conference on Acoustics, Speech and Signal Processing (ICASSP)
(pp. 7084–7088). IEEE.
<https://doi.org/10.1109/ICASSP40776.2020.9054297>

O'Shaughnessy, D. (2000). Speech communications: Human and machine
(2nd ed.). IEEE Press.

OECD. (2019). Recommendation of the Council on Artificial Intelligence.
OECD/LEGAL/0449.

<https://legalinstruments.oecd.org/en/instruments/OECD-LEGAL-0449>

Park, D. S., Chan, W., Zhang, Y., Wang, C. C., Zoph, B., Cubuk, E. D.,
& Le, Q. V. (2019). Specaugment: A simple data augmentation method
for automatic speech recognition. In Interspeech 2019
(pp. 2613–2617). ISCA.
<https://doi.org/10.21437/Interspeech.2019-2680>

Rabiner, L. R. (1989). A tutorial on hidden Markov models and selected
applications in speech recognition. *Proceedings of the IEEE*, 77(2),
257–286. <https://doi.org/10.1109/5.18626>

Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., &
Sutskever, I. (2023). Robust speech recognition via large-scale
weak supervision. In *International Conference on Machine Learning*
(pp. 28492–28518). PMLR.
<https://doi.org/10.48550/arXiv.2212.04356>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L.,
Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is
all you need. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach,
R. Fergus, S. Vishwanathan, & R. Garnett (Eds.), *Advances in
Neural Information Processing Systems* (Vol. 30, pp. 5998–6008).
Curran Associates, Inc.

Zeghidour, N., Luebs, A., Omran, A., Skoglund, J., & Tagliasacchi, M.

(2021). SoundStream: An end-to-end neural audio codec. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 29, 3451–3460. <https://doi.org/10.1109/TASLP.2021.3129994>

Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2019). BERTScore: Evaluating text generation with BERT. arXiv preprint arXiv:1904.09675. <https://doi.org/10.48550/arXiv.1904.09675>